AI WAY

Servicio 01

Escucha Digital con Cifras Defendibles

Menos ruido, temas nuevos, números auditables.



Tres dolores de la escucha digital, y lo que cuestan

01

Ruido

Buena parte de lo que trae la herramienta no habla de tu marca.

Por qué importa

Filtrar con palabras clave tira menciones buenas.

02

Cifras que no se sostienen

Un cero que era «no medido», una red bajada a medias.

Por qué importa

Una cifra equivocada en el comité destruye la credibilidad del área.

03

Temas impuestos

La taxonomía genérica no ve lo que la gente de verdad comenta.

Por qué importa

Una crisis detectada tarde cuesta días de reacción.

Enfoque

Medir antes de afirmar

01

Cascada barata → cara

Reglas, luego un modelo local; el LLM solo para la franja de duda.

02

Taxonomía + descubrimiento

El diccionario del cliente más los temas que no sabía que existían.

03

QA de doble camino

Cada cifra por dos rutas; si no cuadran, no se entrega.

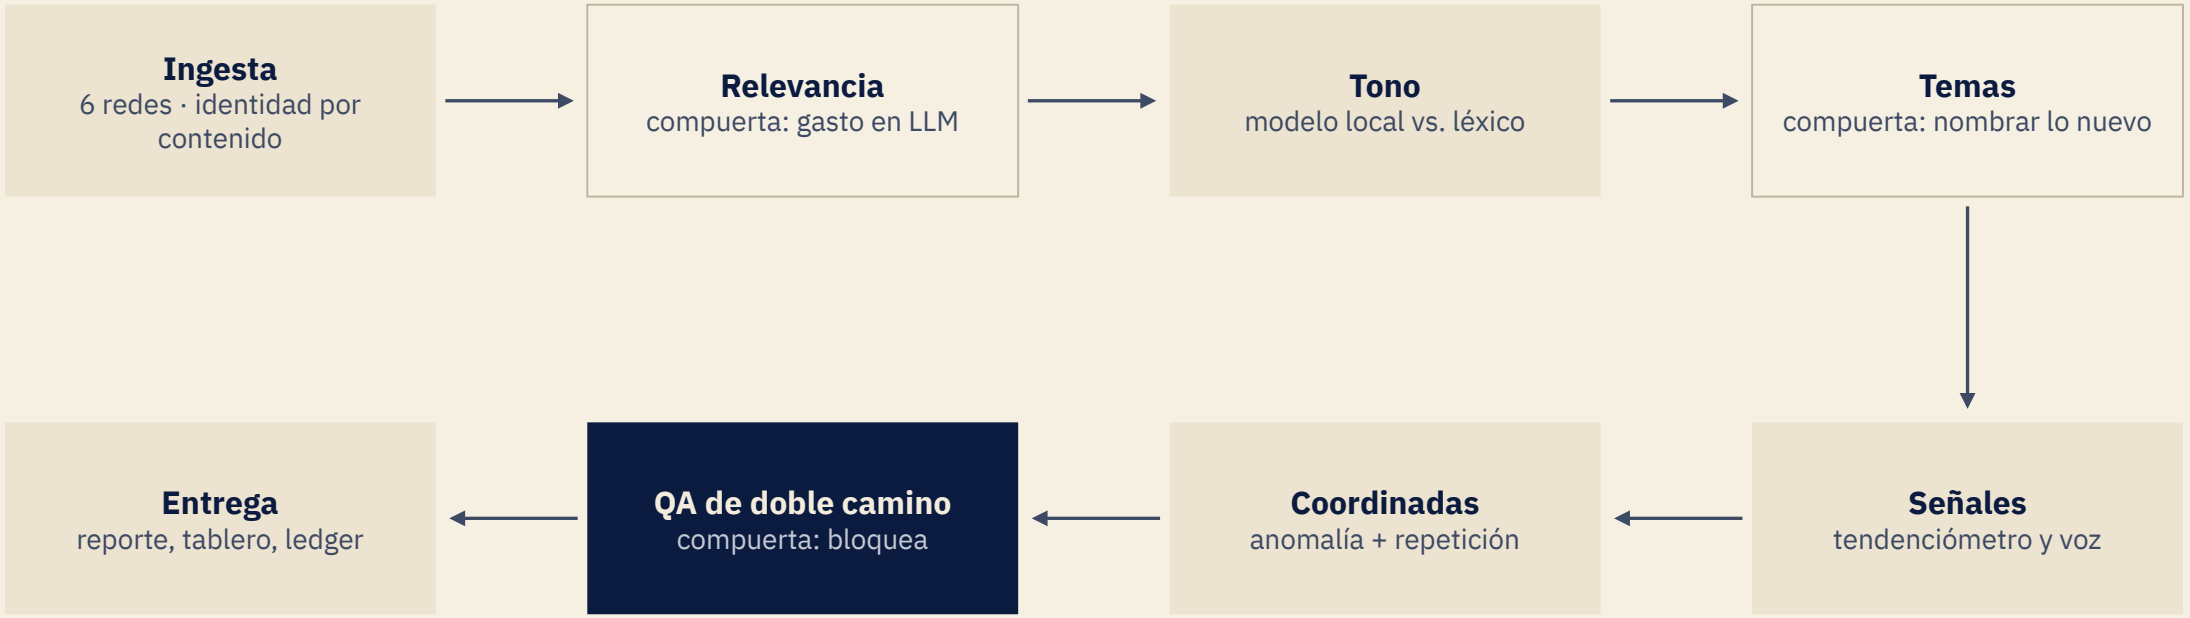
04

Validación humana

Kappa y F1 contra una muestra etiquetada, en cada entrega.

Cada cifra con su denominador, su cobertura y un segundo cálculo.

Ocho pasos, tres compuertas humanas



Con borde: una persona aprueba · azul: el QA detiene la entrega si no cuadra · Datos ilustrativos (sintéticos) · AI Way

Lo que la demo recuperó de la verdad del simulador

0.96

F1 de relevancia

vs. 0.77 con solo reglas · recall 0.96

4.4 %

de las menciones fue al LLM

93 % menos coste que mandarlo todo (tarifa supuesta)

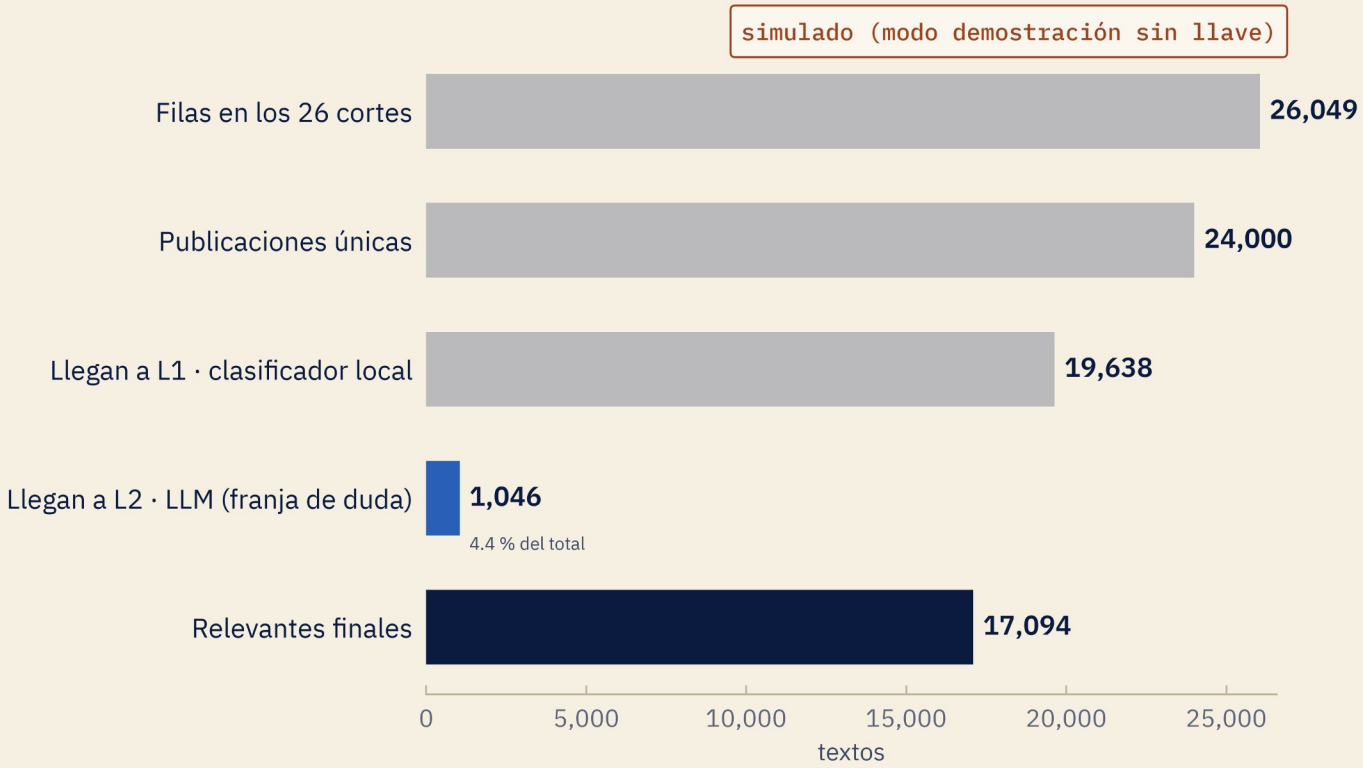
3 de 3

defectos bloqueados por el QA

0 falsas alarmas

Gold de prueba de 604 menciones · corpus de 24,000 publicaciones · Datos ilustrativos (sintéticos) · AI Way

Solo 4.4 % de las menciones necesitó un LLM



Fuente: simulación propia · L2 pregrabado · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) F1 de 0.96 frente a 0.77 con solo reglas; recall 0.96.

(2) Coste 93 % menor que mandar todo al LLM, con tarifa supuesta.

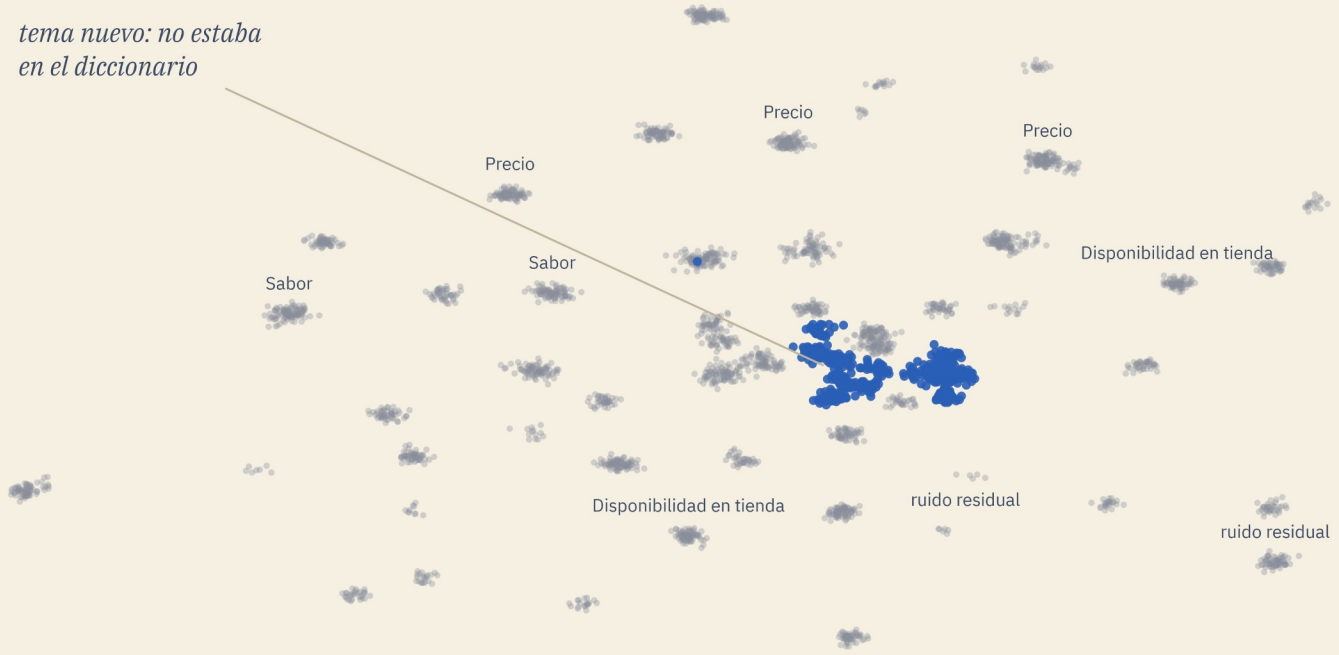
(3) Una exclusión dura habría tirado 0.5 % de las relevantes.

Límite declarado

Texto sintético, más regular que el real: cota optimista. Veredictos del LLM simulados (modo sin llave).

El diccionario no veía «envase que gotea»; los datos sí

simulado (modo demostración sin llave)



Fuente: simulación propia · nombre del tema: LLM simulado · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) 456 menciones sin tema formaron un grupo nuevo, 86 % puro.

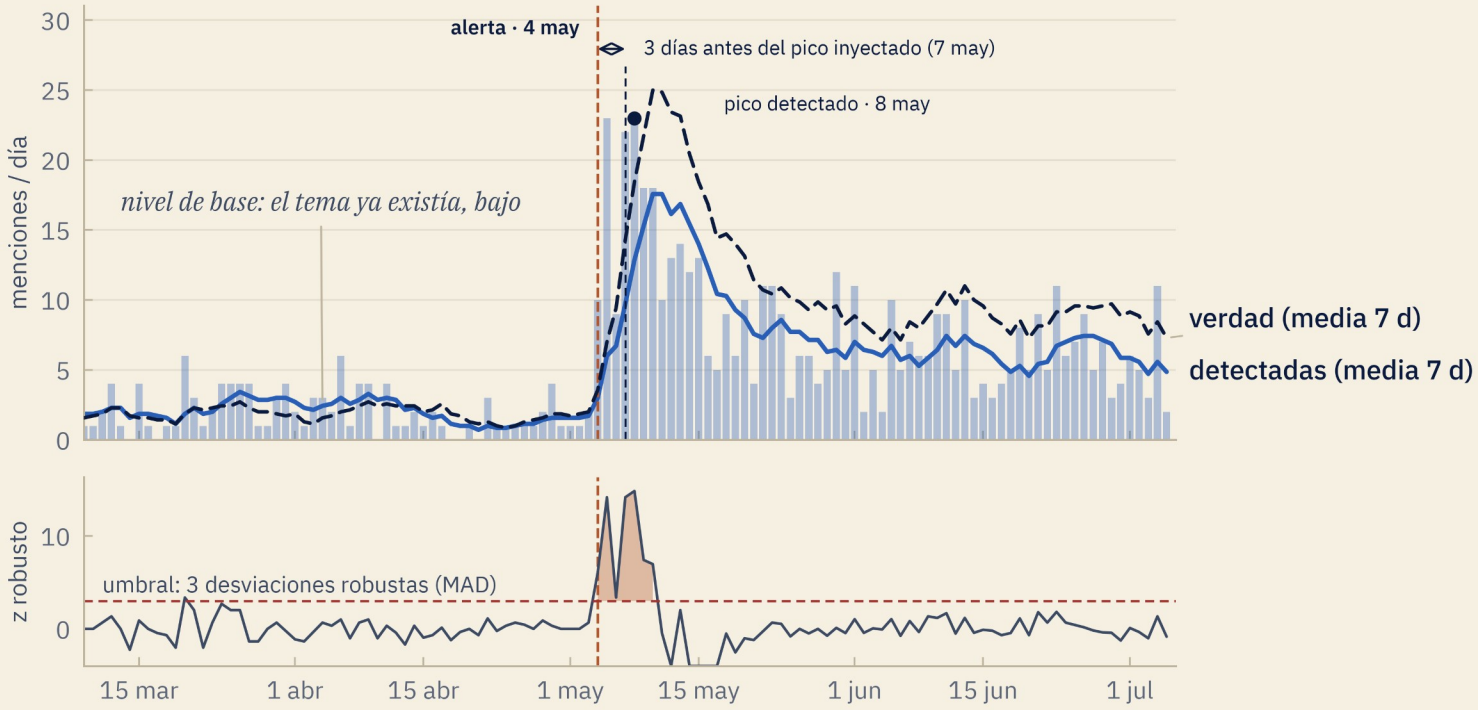
(2) Un LLM propone el nombre (aquí simulado) y una persona lo aprueba.

(3) Con sus términos en el diccionario, el tema se sigue a diario.

Límite declarado

El grupo recoge 63 % de esas menciones; HDBSCAN deja 22 % sin grupo.

La alerta salta 3 días antes del máximo



Fuente: simulación propia · detector causal: solo usa el pasado · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) Alerta el 4 de may; el pico inyectado fue el 7 de may.

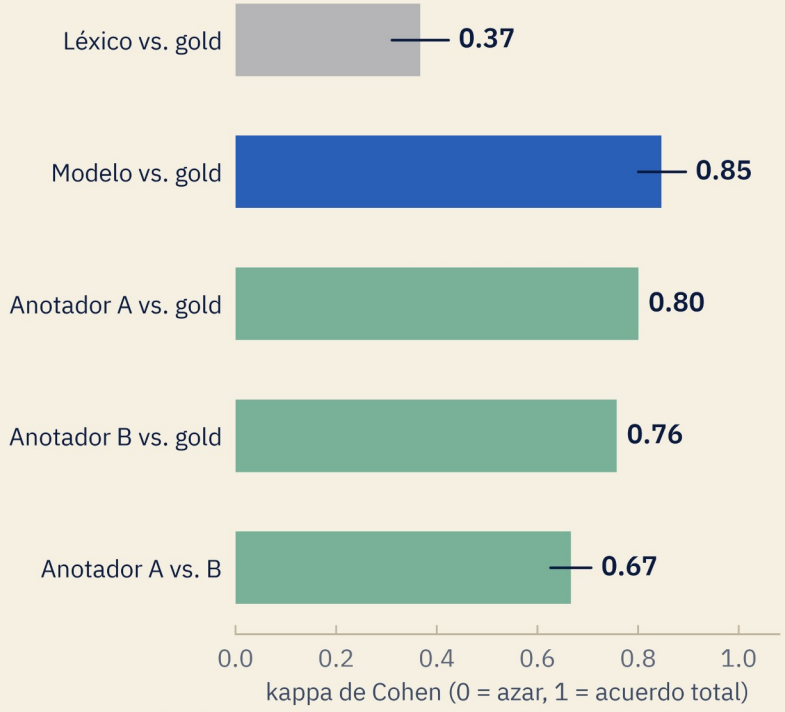
(2) El pico detectado quedó a 1 día del real.

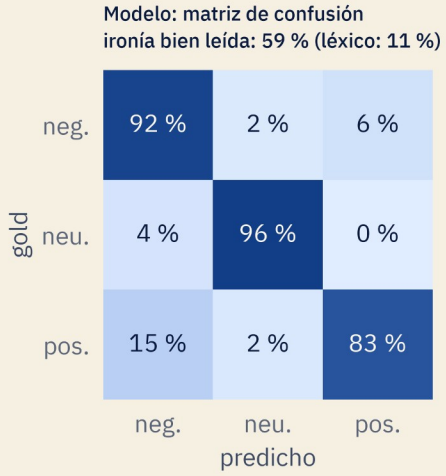
(3) Falsas alertas de este tema en 26 semanas: 1.

Límite declarado

El detector solo usa el pasado; el tema nuevo se descubrió con el periodo completo.

Modelo vs. gold: kappa 0.85; dos personas entre sí: 0.67





Fuente: simulación propia · anotadores simulados · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) El léxico genérico se queda en kappa 0.37.

(2) Falla donde falla la gente: lee bien 59 % de la ironía.

(3) El acuerdo se reporta en cada entrega, no se supone.

Límite declarado

Aquí el gold es la verdad del simulador. En un proyecto real lo etiquetan personas y su acuerdo es el techo práctico.

Tres cifras plausibles pero falsas no llegaron al cliente

INCIDENTE INYECTADO	CAMINO A	CAMINO B	DIFERENCIA	ESTADO
Duplicados entre cortes mismo contenido, URL distinta	**23,727** por contenido	**24,622** por id de origen	**+3.8 %** volumen inflado	**× bloqueado** ✔ cuadra en corrida 2
Archivo omitido al reanudar corte 21 · facebook	**786** cargadas	**979** declaradas	**-19.7 %** semana incompleta	**× bloqueado** ✔ cuadra en corrida 2
Cobertura de una red bajo 10 % corte 12 · instagram	**11** recibidas	**143** esperadas	**-92.3 %** red casi en cero	**× bloqueado** ✔ cuadra en corrida 2

Corrida 1: 4 bloqueos (el archivo omitido también dejó en 0 la cobertura de su red) · falsas alarmas: 0 · corrida 2: 0 bloqueos

Fuente: simulación propia · defectos inyectados · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) 3 de 3 defectos inyectados bloquearon el reporte; 0 falsas alarmas.

(2) Los duplicados habrían inflado el volumen 3.8 %.

(3) Tras re-descargar, los dos caminos cuadran y el reporte sale.

Límite declarado

El QA atrapa lo que no cuadra; no corrige un dato bien contado pero mal clasificado.

Caso de estudio

El QA bloqueó entregas con cifras erróneas pero plausibles

En operación

ESCUCHA DIGITAL · CLIENTE CORPORATIVO VÍA DESPACHO

Problema

Entregas diarias sobre un tema de alta exposición pública, con cifras difíciles de reproducir.

Qué hicimos

- Motor de 21 pasos con cascada de relevancia
- Pasos que se detienen antes de gastar y ledger de coste
- QA de doble camino; cortes coyunturales en ≤ 2 h
- Otro caso: una plantilla operó ~25 carpetas de cliente

~26 %

conteo menor por un archivo saltado: bloqueado

~3.2×

coste real vs. presupuesto en la auditoría previa

Lo que no está medido

El caso no publica cifras de acierto de clasificación; aquí solo se citan coste, reproducibilidad y bloqueos.

Caso real anonimizado · cifras sensibles en relativo

Tres formas de empezar

Nº 01

Básico

Diagnóstico puntual

- 1 marca + 2 competidores
- Hasta 4 redes, 3 meses
- Taxonomía estándar del sector
- Reporte ejecutivo y sábana

2 a 3 semanas

Nº 02

Pro

Monitoreo recurrente

- 1 marca + hasta 5 competidores
- Taxonomía a medida + temas nuevos
- Tablero y validación con muestra
- Ledger de coste

Arranque en 4 semanas

Nº 03

Enterprise

Operación diaria y crisis

- Cortes coyunturales en ≤ 2 h
- QA de doble camino
- Cuentas coordinadas
- Pipeline en la nube del cliente

Arranque en 6 a 8 semanas

Herramientas, elegidas por el problema

DATOS	Python · pandas · DuckDB · BigQuery
MODELOS	embeddings locales · scikit-learn · UMAP · HDBSCAN
IA	LLM con caché · modo sin llave · ledger de coste
ENTREGA	tablero HTML · Power BI · reporte DOCX

Dónde la escucha digital mueve tu negocio

VENTAS

¿Qué quejas nos están costando clientes?

Agrupamos las menciones por tema con tu taxonomía y medimos qué quejas crecen por marca y por red.

→ *Priorizar qué corregir primero en producto o servicio.*

MARKETING

¿La campaña generó conversación o solo ruido?

Quitamos lo irrelevante con la cascada de relevancia y comparamos volumen, tono y temas antes y después.

→ *Ajustar mensajes y canales con cifras que se pueden auditar.*

OPERACIÓN Y COSTOS

¿Cuánto pagamos por leer menciones que no sirven?

Reglas y un modelo local resuelven casi todo; el LLM solo ve la franja de duda, con ledger de coste.

→ *Fijar un presupuesto de escucha por corte y vigilarlo.*

RIESGO Y CRISIS

¿Cómo vemos venir una crisis antes de que estalle?

El tendenciómetro mide la aceleración de cada tema y alerta en la subida; separa las cuentas coordinadas.

→ *Activar el protocolo de crisis cuando todavía hay margen.*

DIRECCIÓN Y ESTRATEGIA

¿Cómo estamos de verdad frente a la competencia?

Medimos voz y tono por competidor con el mismo filtro y un QA de doble camino en cada corte.

→ *Llevar al comité cifras que resisten una auditoría.*

PRODUCTO E INNOVACIÓN

¿De qué habla la gente que no está en nuestro radar?

Embeddings y HDBSCAN agrupan lo que el diccionario no cubre; un LLM propone el nombre y una persona aprueba.

→ *Sumar el tema nuevo al seguimiento y al plan de producto.*

Ejemplos de aplicación; el alcance se define en el diagnóstico

AI WAY

Hablemos

Rigor de físico, validación honesta, operación en producción y coste vigilado. En 30 minutos te digo si tu escucha se puede auditar y cómo lo mediríamos.

Agenda un diagnóstico

Nombre	Andrés Vázquez Macías
Correo	avm.48p1@gmail.com
Web	andresvama.github.io
LinkedIn	linkedin.com/in/andrés-vázquez-macías-727278242
GitHub	github.com/AndresVAMA



AI Way: soluciones que te hacen decir «¡ay, wey!»