AI WAY

Servicio 05

Datos que Llegan Solos y Cuadran

Ingesta automática, cifras auditables.



Hoy el reporte se arma a mano y nadie puede repetirlo

Lo que pasa hoy

- Alguien copia de la API, la base y el Excel cada lunes
- Los cruces se rompen cuando una fuente cambia una columna
- Dos personas sacan dos cifras distintas del mismo mes

Lo que cuesta

- Horas de trabajo manual cada semana
- Datos que llegan tarde, cuando ya no sirven para decidir
- Un tablero con una cifra mala deja de usarse

Una cifra equivocada cuesta más que un dato que falta

Cifra plausible pero falsa

- Accidentes contados dos veces parecen una crisis de seguridad
- Reintegros sumados como gasto inflan el costo
- La dirección deja de confiar en el tablero entero

Dato que llega tarde

- Un cambio de tarifa publicado y visto una semana después
- Un día sin datos que el reporte muestra como «cero viajes»
- La ventana para actuar ya se cerró

Enfoque

Cuatro reglas antes de publicar una cifra

01

Perfilar antes de modelar

Todas las filas de todas las tablas, no una muestra de 100.

02

Incremental e idempotente

Marca de agua con solape; correr dos veces da lo mismo.

03

QA que bloquea

Doble camino, cobertura y «ausencia no es cero»; si falla, no se publica.

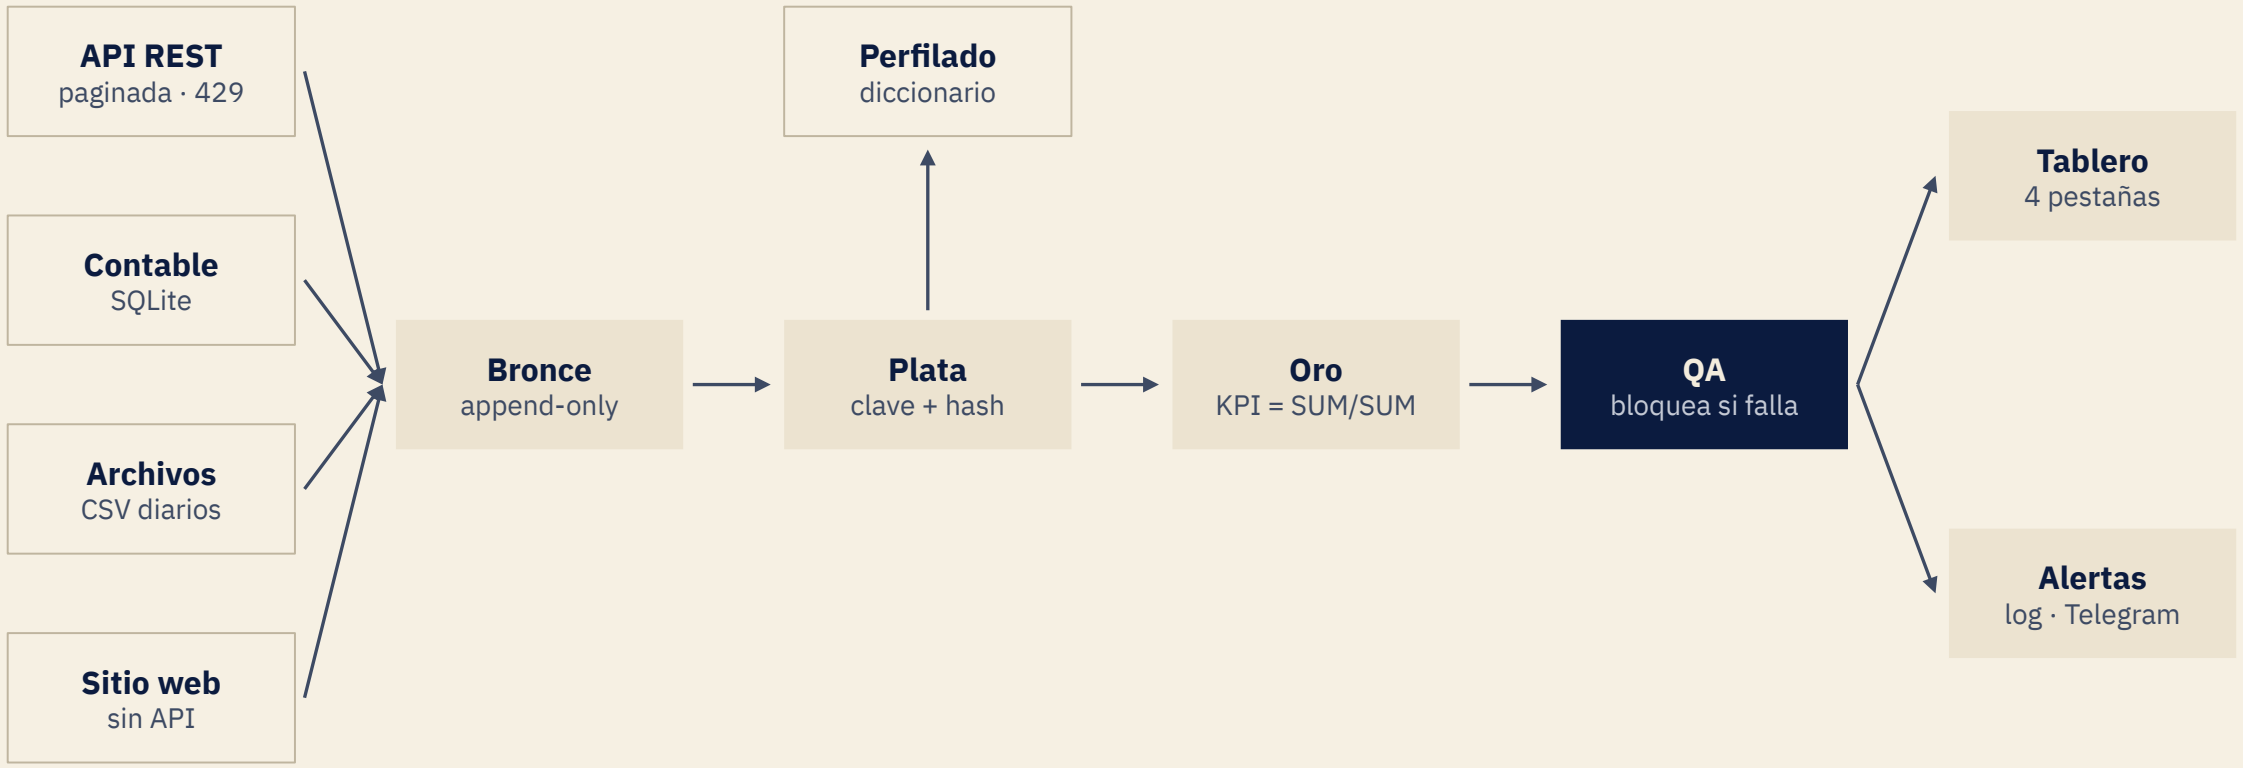
04

Verdad conocida primero

Probamos el pipeline con defectos plantados antes de tocar tus datos.

Tus datos llegan solos, no se duplican y ninguna cifra sale sin cuadrar dos veces.

Cuatro fuentes, un solo dato confiable



El perfilado encontró 7 de 7 defectos; una muestra, 3

columna	% poblado	valor top	cardinal.	alerta del perfilado
viaje_id*	100	0.0	0.25	! 76024 filas duplicadas por clave + hash
km*	65	0.8	0.01	! renombre · km ↔ kilometros
kilometros*	35	0.8	0.01	! cobertura baja · 35.0 % poblado
fecha	100	0.7	7e-3	! día sin dato · 2026-03-16 (nulo, no cero)
pasajeros	100	5.1	3e-3	! fuera de rango · 775 viajes > capacidad
ingreso	100	0.1	0.60	! razón · promedio ≠ SUM/SUM (+18.3 %)
atraso_min	100	99.996	8e-5	! constante oculta · 99.996 % de filas = 0
ocupacion	40	0.7	0.03	! cobertura baja · 40.0 % poblado
ruta	100	8.0	9e-4	✔ sin alerta
monto	100	0.0	0.99	! negativos · 305 reintegros
evento_id (nov.)	100	0.2	0.50	! 1.99 filas por evento (apertura y cierre)
capacidad	100	40.0	0.03	✔ sin alerta

defecto plantado	todo	muestra
D1 atraso casi constante	✔	×
D2 ocupación 60 % vacía	✔	×
D3 duplicados del solape	✔	×
D4 pasajeros > capacidad	✔	✔
D5 km → kilometros	✔	✔
D6 día sin datos	✔	×
D7 promedio de razones	✔	✔

perfilado 7 de 7 · muestra de 100 filas 3 de 7

* bronce, antes de deduplicar · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) La muestra ve lo que salta a la vista: pasajeros imposibles y un renombre de columna.

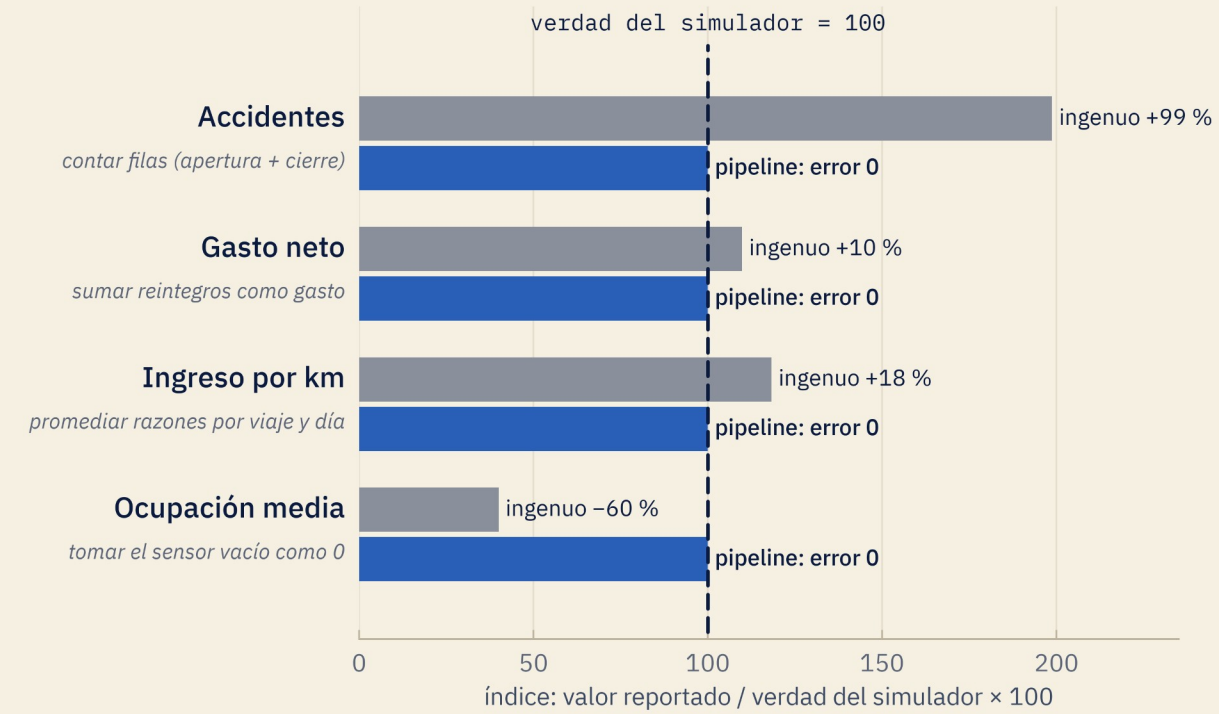
(2) No ve el atraso casi constante, los duplicados del solape ni el día sin datos.

(3) Mismos detectores en ambos casos; solo cambia cuántas filas miran.

Límite declarado

Los defectos los plantamos nosotros: es la verdad del simulador, no un cliente.

Contar filas duplica los accidentes; dividir agregados corrige el ingreso/km



Mismos datos limpios, distinta fórmula · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) Accidentes: +99 % al contar filas en vez de eventos.

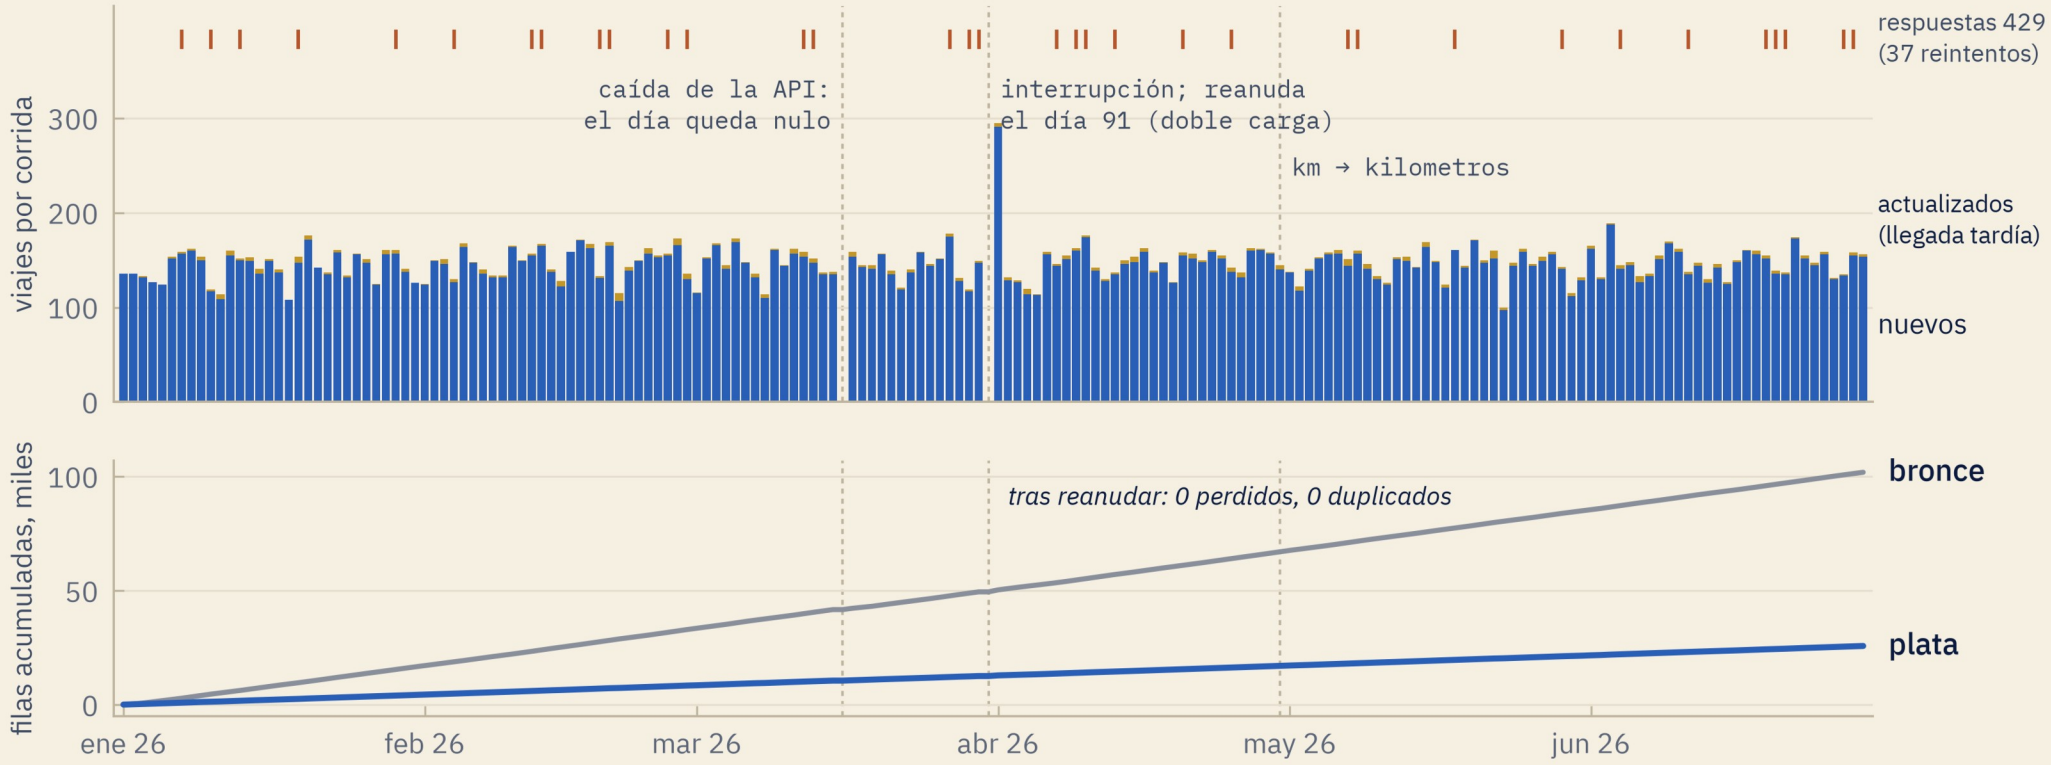
(2) Ingreso por km: +18 % al promediar razones; gasto neto +10 % con reintegros como gasto.

(3) El pipeline cuadra con la verdad del simulador en los cuatro KPI.

Límite declarado

Mismos datos limpios en ambos casos: el error ingenuo es solo de fórmula.

180 corridas, 0 registros perdidos



Fuente: simulación propia, 180 corridas diarias · Datos ilustrativos (sintéticos) · AI Way

Correr dos veces da el mismo oro, bit a bit

0

registros perdidos al reanudar

y 0 duplicados tras matar el proceso el día 90

0

duplicados en plata

76 520 repeticiones de bronce eliminadas por clave + hash

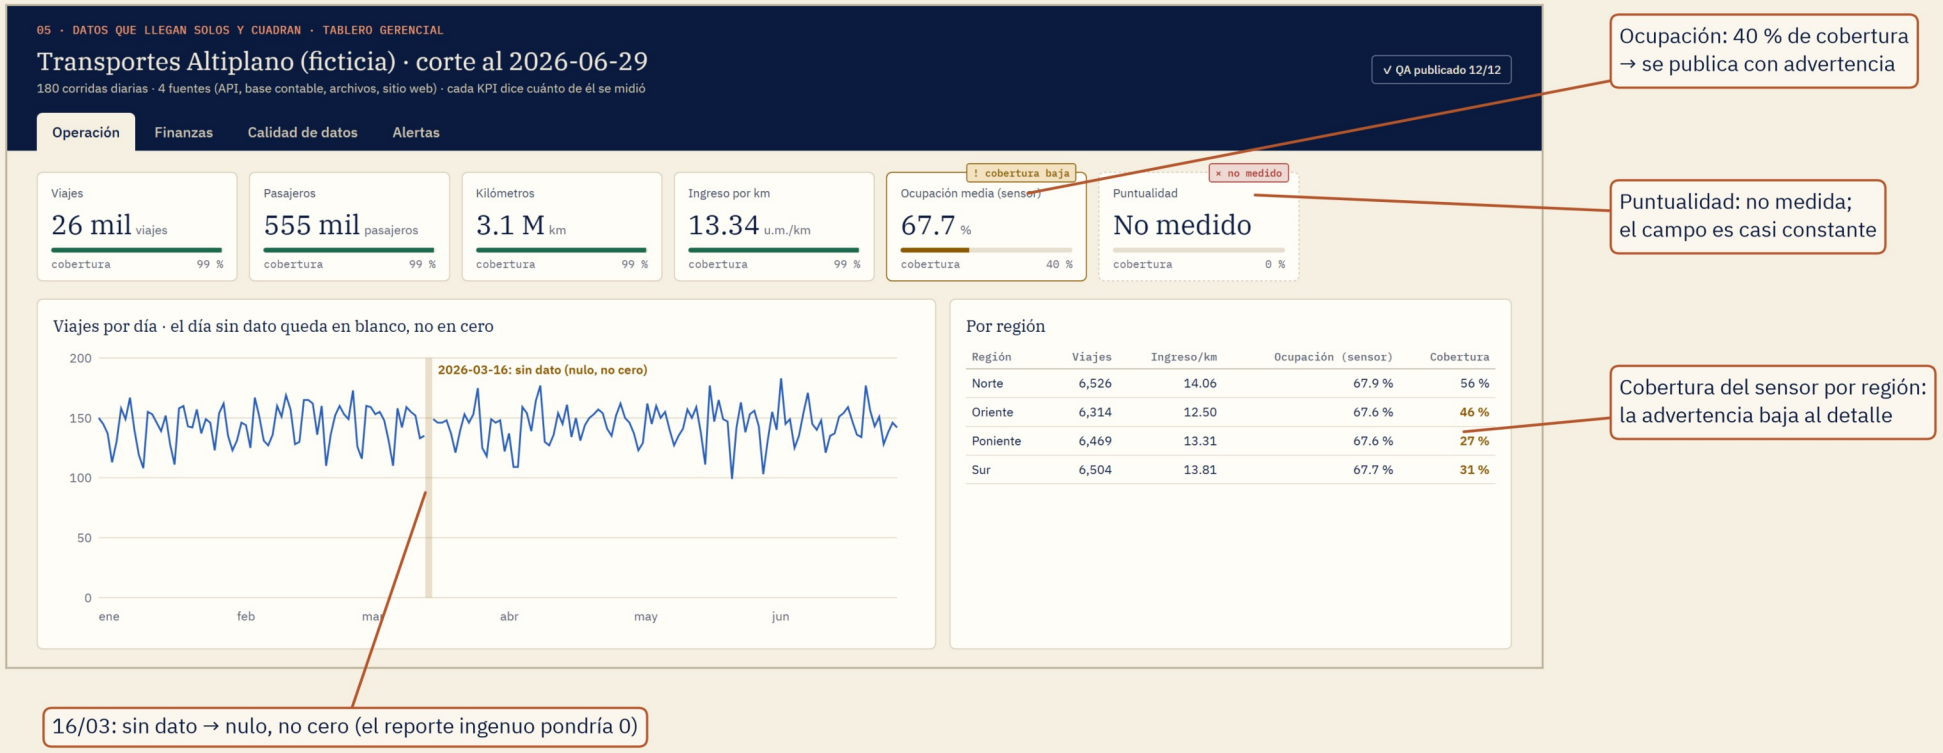
~40×

más rápida la corrida incremental

piso entre corridas (0.07 s vs 3.2 s en esta); sin solape se perderían 1 193 registros

Hash de oro idéntico en dos corridas: sí · verdad del simulador · Datos ilustrativos (sintéticos) · AI Way

Cada KPI dice cuánto de él se midió



Fuente: captura del tablero HTML de la demo · Datos ilustrativos (sintéticos) · AI Way

Caso de estudio

Un tablero gerencial que hoy cuadra dos veces

En curso

TRANSPORTE INTERURBANO DE PASAJEROS · VÍA CONSULTORA DE DATOS

Problema

Una plataforma de BI gerencial con fuentes que nadie había perfilado completas.

Qué hicimos

- Ingesta incremental con solape y deduplicación por hash
- Lakehouse medallón y diccionario de datos por perfilado
- Modelo semántico de cientos de medidas y verificación de fórmulas

99.99 %

de filas con el mismo atraso: el campo no se capturaba

~2×

novedades contadas por fila en vez de por evento

Lo que no está medido

Proyecto en curso: algunos KPI aún tienen cobertura baja y se publican con advertencia. La meta de margen difería ~7× según su definición.

Caso real anonimizado · cifras sensibles en relativo

Tres formas de empezar

Nº 01

Básico

Saber qué tan sanos están tus datos

— Diccionario por perfilado de hasta 30 tablas
— Mapa de fuentes
— Problemas de calidad priorizados

1 a 2 semanas

Nº 02

Pro

Datos que llegan solos a un tablero

— Hasta 6 fuentes incrementales
— Bronce, plata y oro
— QA que bloquea y alertas
— Un tablero gerencial

4 a 6 semanas

Nº 03

Enterprise

Plataforma de BI completa

— Modelo semántico de cientos de medidas
— Seguridad por roles
— Monitoreo de 20+ fuentes web
— Runbook y soporte

8 a 12 semanas + soporte

Herramientas, elegidas por el problema

INGESTA	Python · requests · tenacity · BeautifulSoup · Selenium / Apify
ALMACÉN	DuckDB · Parquet · Microsoft Fabric · BigQuery · SQL Server / Oracle
MODELO Y QA	SQL · DAX · doble camino · perfilado propio
ENTREGA	Power BI · HTML + JSON estático · Telegram · Google Chat

Qué decisiones habilita un dato que llega solo

VENTAS E INGRESOS

¿Cuánto vendimos ayer por región, sin esperar al lunes?

Ingesta incremental diaria de API, base y archivos a bronce, plata y oro, con KPI listos para el tablero.

→ *Corregir el rumbo comercial con los datos del día anterior.*

MARKETING

¿Cuánto rinde cada canal si los datos viven en cinco lados?

Unificamos las fuentes en un modelo con definiciones exactas: cocientes de agregados, no promedios de razones.

→ *Mover inversión entre canales con una sola versión de la cifra.*

OPERACIÓN Y COSTOS

¿Cuántas horas se van en armar el reporte a mano?

Automatizamos la ingesta con marca de agua y solape; se reanuda sola y correr dos veces da lo mismo.

→ *Liberar al equipo del copiado para que analice y decida.*

RIESGO Y REPUTACIÓN

¿Qué cifra del tablero está mal y nadie lo ha notado?

QA de doble camino, cobertura por KPI y «ausencia no es cero»: si una cifra no cuadra, no se publica.

→ *Presentar a la dirección solo cifras verificadas.*

DIRECCIÓN Y ESTRATEGIA

¿Qué tan sanos están los datos antes de invertir en BI?

Perfilamos todas las filas de todas las tablas: tipos, % poblado, rangos, columnas vacías o constantes.

→ *Priorizar qué fuentes arreglar antes de construir tableros.*

PRECIOS Y REGULACIÓN

¿Un competidor o un regulador cambió algo en su sitio?

Scrapers vigilan sitios sin API y alertan por Telegram, Google Chat o correo cuando cambia una tarifa o norma.

→ *Reaccionar a un cambio de tarifa o de norma el mismo día.*

Ejemplos de aplicación; el alcance se define en el diagnóstico

AI WAY

Hablemos

Cuéntame qué reporte armas a mano cada semana. En 30 minutos te digo qué fuentes se pueden automatizar, qué cifras conviene verificar primero y qué no te puedo prometer.

Agenda un diagnóstico

Nombre	Andrés Vázquez Macías
Correo	avm.48p1@gmail.com
Web	andresvama.github.io
LinkedIn	linkedin.com/in/andrés-vázquez-macías-727278242
GitHub	github.com/AndresVAMA



AI Way: soluciones que te hacen decir «¡ay, wey!»