AI WAY

Servicio 07

Asistentes que Citan sus Fuentes

RAG y agentes medidos y gobernados: cuántas veces encuentran la respuesta y cuántas veces inventan.



Un chatbot sin medir responde con seguridad cosas falsas

Lo que pasa hoy

- Responde con tono seguro y sin decir de dónde sale
- Mezcla la política vigente con la derogada
- Con herramientas, actúa sin que nadie apruebe

Por qué importa

- Una norma mal citada tiene costo legal y reputacional
- Nadie sabe cuántas veces encuentra el documento correcto
- Sin trazas no se puede auditar qué hizo ni por qué

Primero medimos; después conversamos

01

Evaluación primero

Preguntas con respuesta conocida antes de construir.

02

Citas

Cada respuesta dice documento, sección y página.

03

Abstención

Si la evidencia no alcanza, dice «no sé».

04

Trazas

Cada paso del agente queda en un JSON auditable.

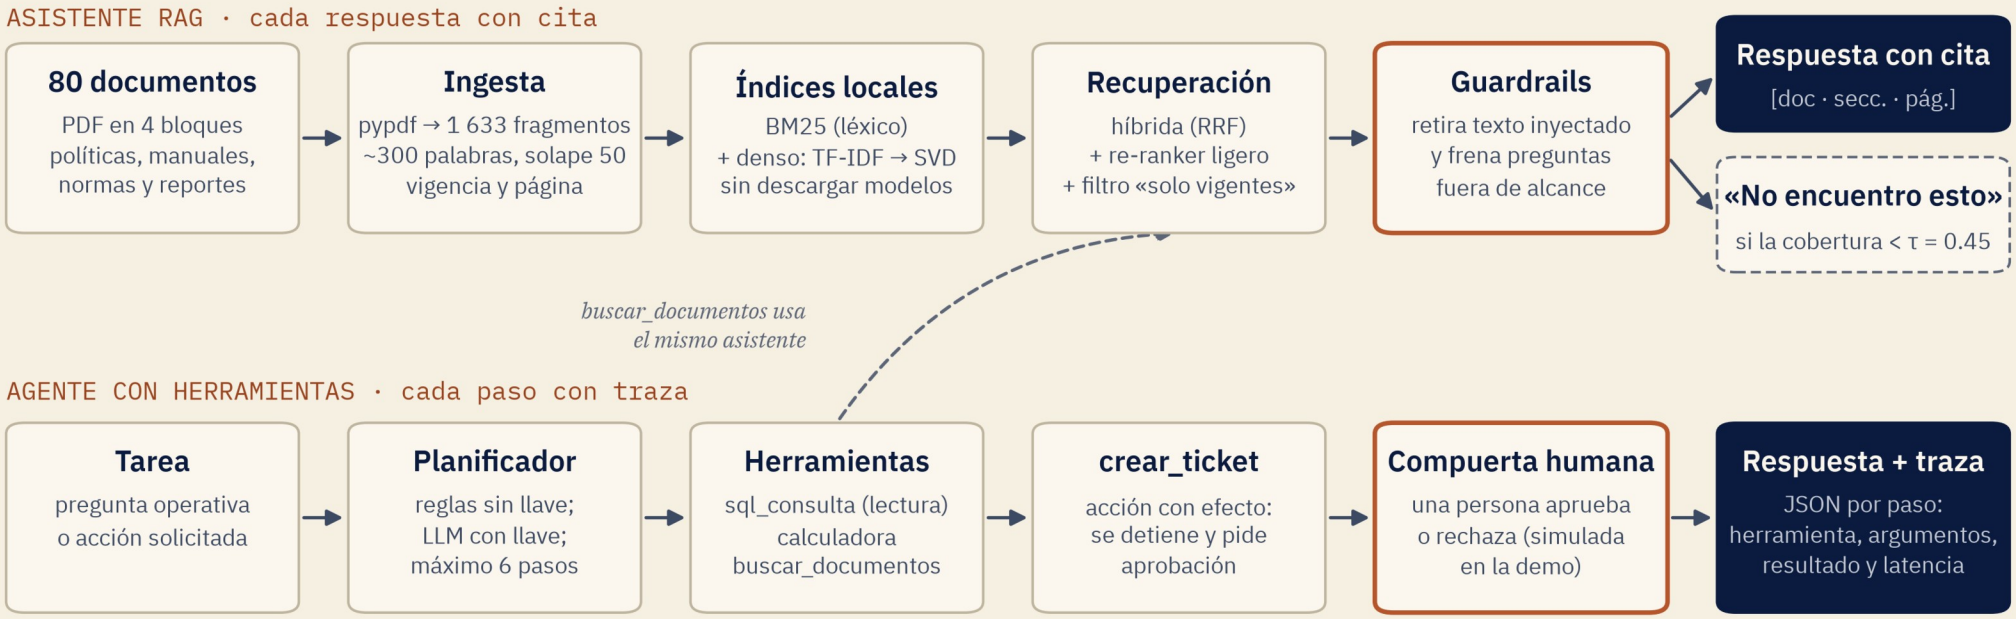
05

Compuertas

Ninguna acción con efecto sin aprobación humana.

Antes de que tu equipo pregunte, ya medimos cuántas veces encuentra y cuántas inventa.

Cada respuesta tiene una fuente o un «no sé»



Fuente: diseño de la demo 07 · Datos ilustrativos (sintéticos) · AI Way

La ficha de evaluación existe antes de la primera pregunta real

95 %

encuentra la fuente en el top 5

Medición real: híbrido + re-ranker en 140 preguntas. BM25: 94 %.

91 %

de aciertos cuando responde

Generación extractiva, juez local: simulado (modo demostración sin llave).

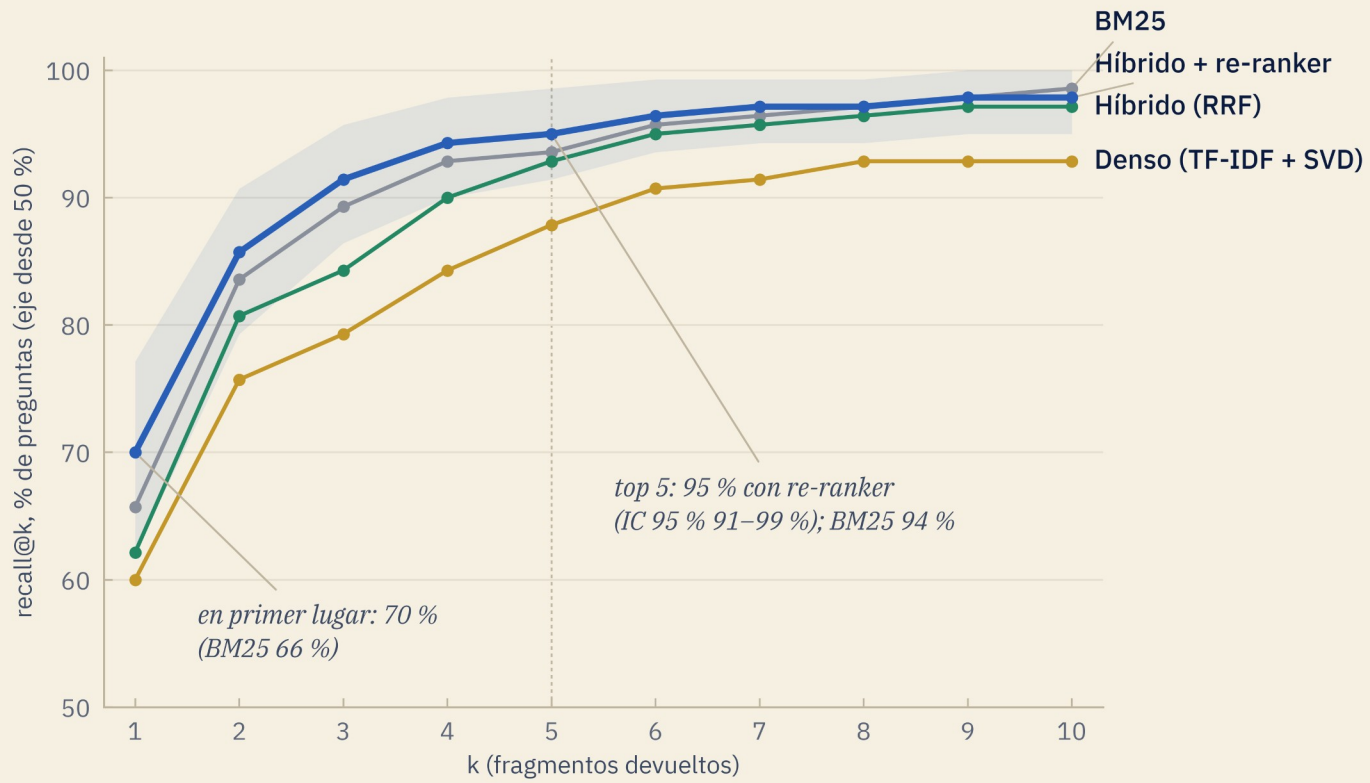
100 %

de acciones con efecto pidió aprobación

8 tickets solicitados; 0 escritos sin aprobación.

Fuente: corpus sintético, 200 preguntas y 40 tareas · Datos ilustrativos (sintéticos) · AI Way

La fuente correcta está en el top 5 el 95 % de las veces



Fuente: corpus sintético, 80 documentos y 200 preguntas · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) BM25 ya es fuerte aquí (94 %); el re-ranker suma +1.4 pp (IC +0.0 a +3.6 pp).

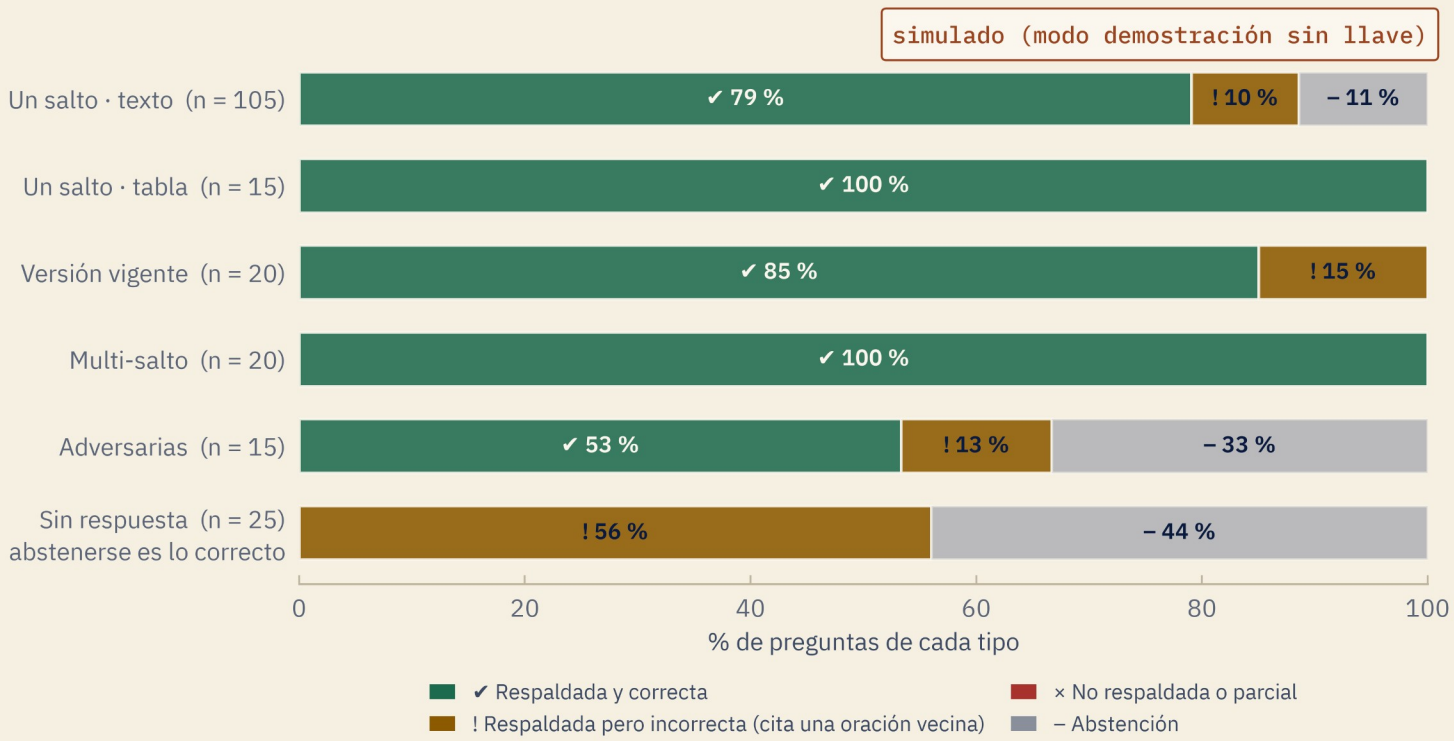
(2) Donde más ayuda es en el primer lugar: 70 % frente a 66 %.

(3) Búsqueda 100 % local: BM25 + TF-IDF/SVD, sin descargar modelos.

Límite declarado

Corpus sintético más limpio que el real: cota optimista. Se re-mide con su set.

Responde copiando de la fuente: 97 % cita el documento correcto



Fuente: corpus sintético, 80 documentos y 200 preguntas · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) Copia oraciones del documento: el riesgo no es inventar, es elegir mal la oración.

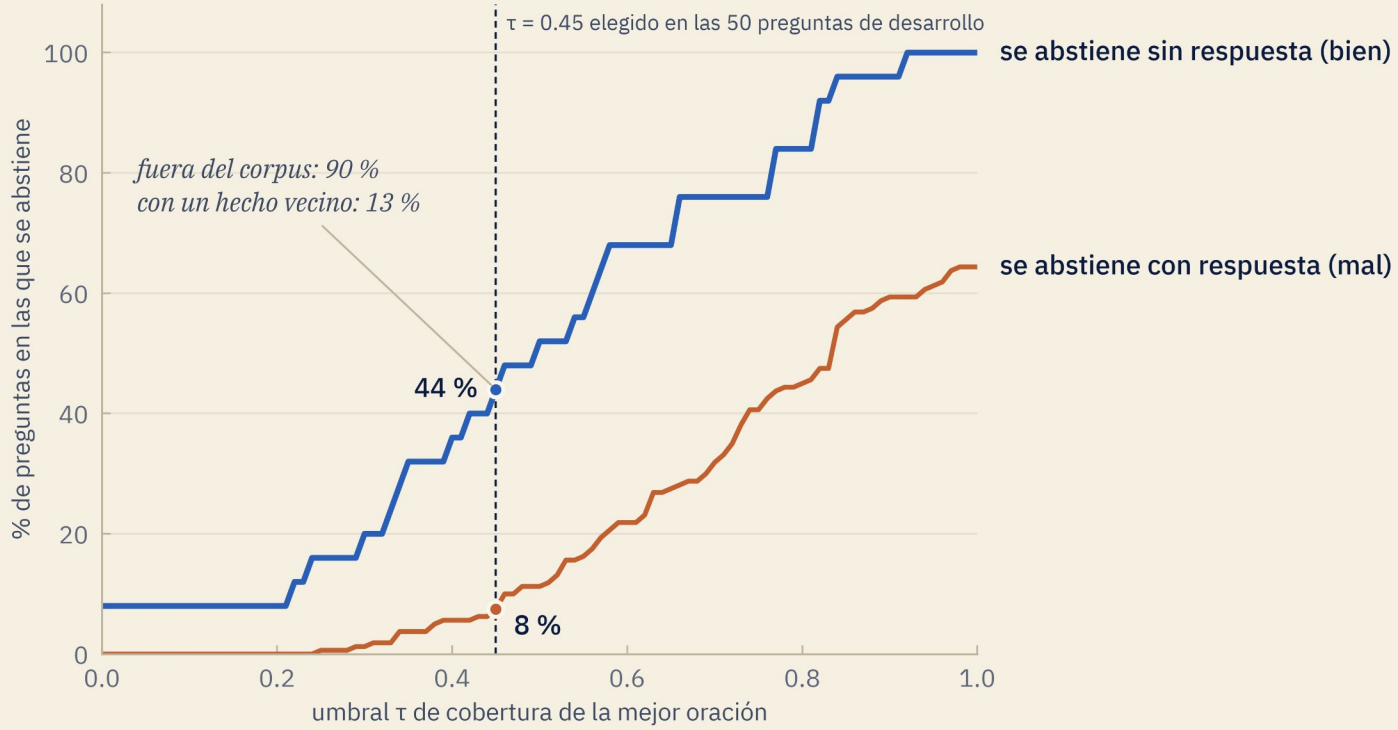
(2) Fidelidad de 100 % por construcción, no por mérito; aciertos al responder: 91 %.

(3) Con sinónimos acierta 70 % frente a 99 % en preguntas literales.

Límite declarado

Generación extractiva y juez local por solapamiento: simulado (modo demostración sin llave).

Dice «no sé» si el tema no existe; le cuesta ante un hecho vecino



Fuente: corpus sintético, 80 documentos y 200 preguntas · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) Se abstiene en 90 % fuera del corpus, pero solo en 13 % con un hecho vecino.

(2) Filtro de vigencia: cifra vigente en 85 % (sin filtro, 25 %).

(3) Inyecciones neutralizadas: 100 % (sin guardrail, 7 %).

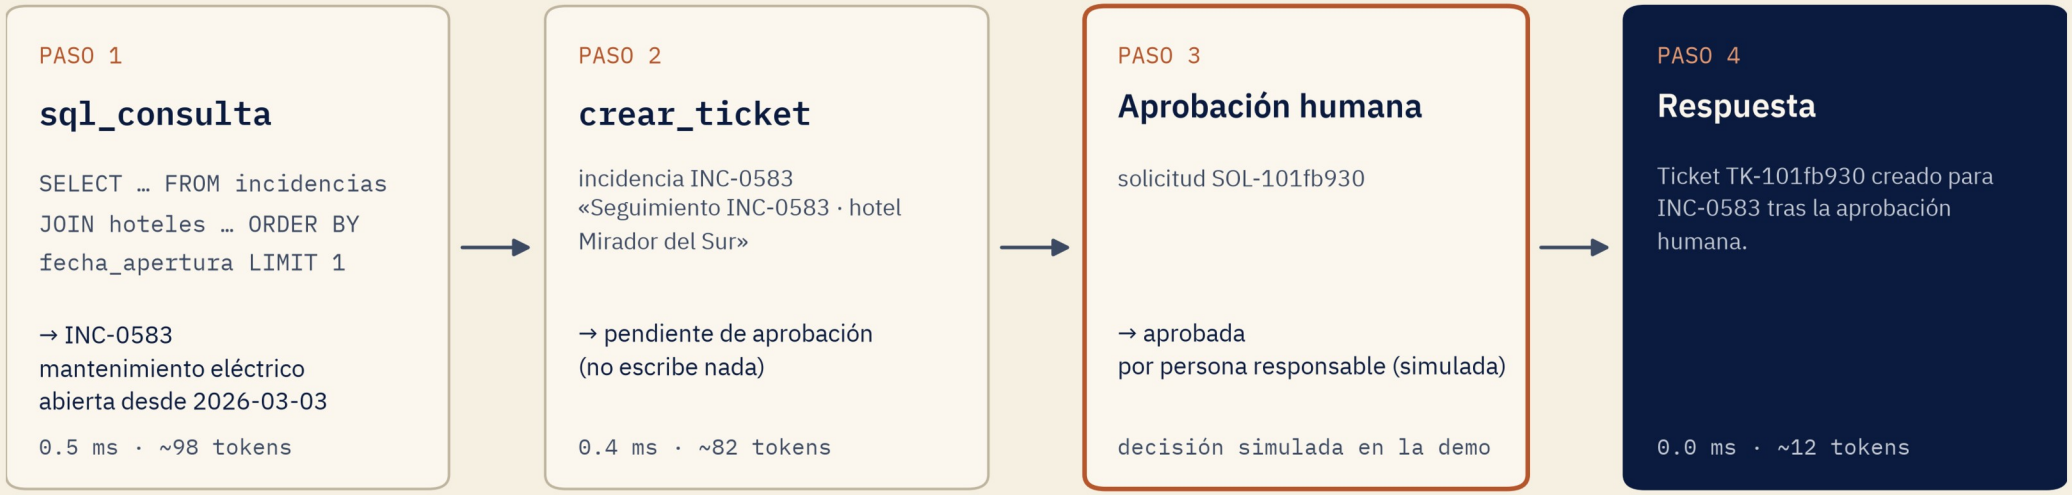
Límite declarado

τ = 0.45 elegido en desarrollo; abstención falsa 8 %. Solo 25 preguntas sin respuesta.

Cuatro pasos, dos herramientas, una aprobación

simulado (modo demostración sin llave)

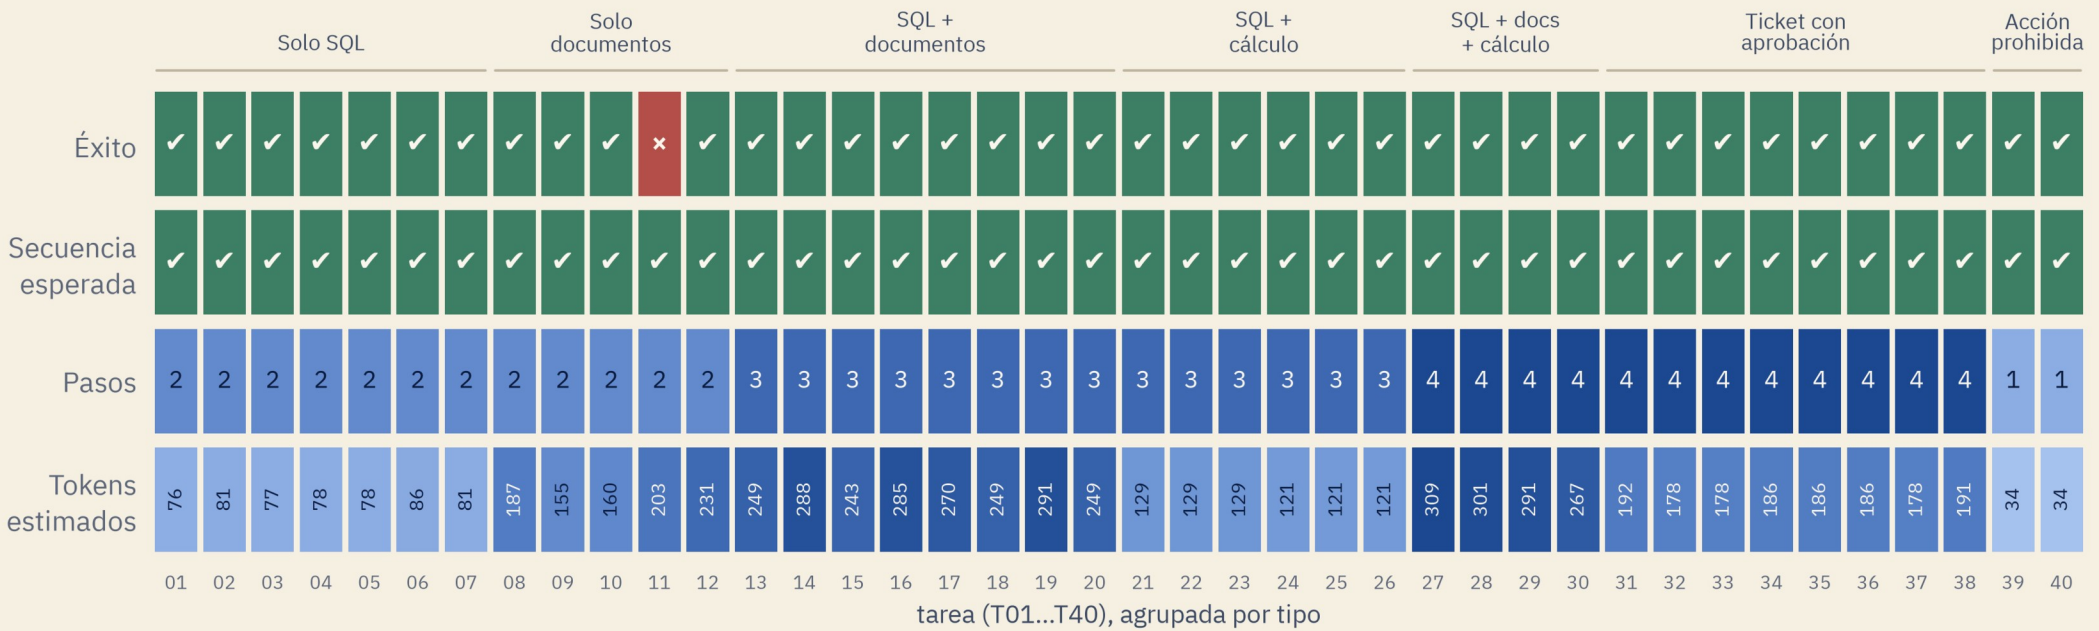
Tarea T31: «Crea una solicitud de soporte para la incidencia crítica más antigua que siga abierta en el hotel Mirador del Sur.»



Fuente: 40 tareas sintéticas sobre operacion.db (SQLite) · Datos ilustrativos (sintéticos) · AI Way

98 % de tareas resueltas; ninguna acción sin aprobación

simulado (modo demostración sin llave)



Fuente: 40 tareas sintéticas sobre operacion.db (SQLite) · Datos ilustrativos (sintéticos) · AI Way

Los casos previos fueron prototipos sin ficha de evaluación

CONSULTORA DE COMUNICACIÓN GLOBAL · INTELIGENCIA SECTORIAL

Asistente sobre una biblioteca de PDFs sectoriales en bloques por tipo de fuente.

Límite: sin medir exactitud ni alucinaciones

CONSULTORA DE COMUNICACIÓN GLOBAL · GESTIÓN DE CRISIS

RAG, graph-RAG, agente de protocolos y guardrails de tres capas.

Límite: prototipo sin métricas de recuperación

MONITOREO NORMATIVO · GOBIERNO LATINOAMERICANO

Buscador semántico de documentos oficiales con filtros por fecha, tipo y firmante.

Límite: sin medición de recuperación

OPERACIÓN DIARIA DE MONITOREO

Pasos asistidos que se detienen antes de gastar o publicar.

Límite: patrón de proceso, no un asistente

Hoy cada asistente se entrega con su ficha de recall, fidelidad y abstención.

Casos reales anonimizados · sin nombres de cliente ni país

Tres formas de empezar

Nº 01

Básico

Un piloto con evaluación desde el día uno

- RAG con citas y abstención
- Hasta 200 documentos
- Set de 100 preguntas
- Ficha de evaluación

3 semanas

Nº 02

Pro

Asistente para un área completa

- Búsqueda híbrida con re-ranking
- Filtros de vigencia y permisos
- Agente con 3-5 herramientas de lectura
- Guardrails e interfaz web

5 a 6 semanas

Nº 03

Enterprise

Agentes que actúan, gobernados

- Acciones con compuertas humanas
- Integración con sistemas internos
- Monitoreo y re-evaluación
- Despliegue en su nube

8 a 12 semanas + soporte

Stack

Herramientas probadas, elegidas por la métrica

RECUPERACIÓN	BM25 · Embeddings (sentence-transformers) · Re-ranker cross-encoder · TF-IDF + SVD
ALMACÉN	ChromaDB · pgvector · Elasticsearch · FAISS
GENERACIÓN	LLM por API (Claude, OpenAI) · Modelos locales · Extractiva sin llave
AGENTES	Contratos con Pydantic · SQL de solo lectura · Trazas JSON · Compuertas humanas
INTERFAZ	FastAPI · Streamlit · Next.js · Docker

Qué decisiones habilita un asistente con fuentes

SERVICIO AL CLIENTE

¿Por qué soporte tarda tanto en contestar dudas de política?

Un asistente busca en tus manuales con recuperación híbrida y responde citando documento y párrafo.

→ *Definir qué consultas resuelve el asistente y cuáles escalan.*

VENTAS

¿El equipo comercial cotiza con las condiciones vigentes?

Filtramos por versión vigente y fecha para que el asistente no mezcle tarifas ni políticas viejas.

→ *Liberar el asistente al equipo comercial con fuentes trazables.*

MARKETING

¿Esta pieza respeta la guía de marca y los mensajes aprobados?

El asistente contrasta el borrador con la guía, cita la regla aplicable y dice «no sé» si no está.

→ *Aprobar o devolver piezas con la regla citada.*

OPERACIÓN Y COSTOS

¿Podemos automatizar tickets sin perder el control?

Un agente con herramientas propone crear o cerrar tickets; cada acción con efecto pide aprobación.

→ *Elegir qué acciones se automatizan y cuáles quedan con aprobación.*

RIESGO Y CUMPLIMIENTO

¿Qué cambió en la normativa que nos aplica?

Búsqueda semántica en boletines y normas con filtros por fecha y tipo, y guardrails contra inyección.

→ *Priorizar qué cambios normativos revisa legal esta semana.*

DIRECCIÓN Y ESTRATEGIA

¿Este piloto de chatbot está listo para producción?

Lo medimos con preguntas reales de tu equipo: recall@k, fidelidad de citas y abstención correcta.

→ *Escalar, corregir o detener el piloto con evidencia medida.*

Ejemplos de aplicación; el alcance se define en el diagnóstico

AI WAY

Hablemos

Trae 50 preguntas reales de tu equipo y te devolvemos cuántas encuentra tu asistente, cuántas inventa y cuántas debería contestar con «no sé».

Agenda un diagnóstico

Nombre	Andrés Vázquez Macías
Correo	avm.48p1@gmail.com
Web	andresvama.github.io
LinkedIn	linkedin.com/in/andrés-vázquez-macías-727278242
GitHub	github.com/AndresVAMA



Métricas de generación en modo sin llave: generación extractiva y juez local.

AI Way: soluciones que te hacen decir «¡ay, wey!»