AI WAY

Servicio 09

Auditoría y Rescate de Ciencia de Datos

Medimos, corregimos y consolidamos sin reescribir lo que funciona.



Cientos de notebooks que nadie se atreve a tocar

Lo que se hereda

- Archivos llamados test, Untitled o final_v2_ok
- Claves de API escritas en el código
- Pipelines que solo entendía quien ya se fue

Lo que nadie sabe

- Cuánto cuesta de verdad cada corrida
- Si dos corridas dan la misma cifra
- Qué archivo alimenta a cuál

Tres riesgos que no aparecen en ningún tablero

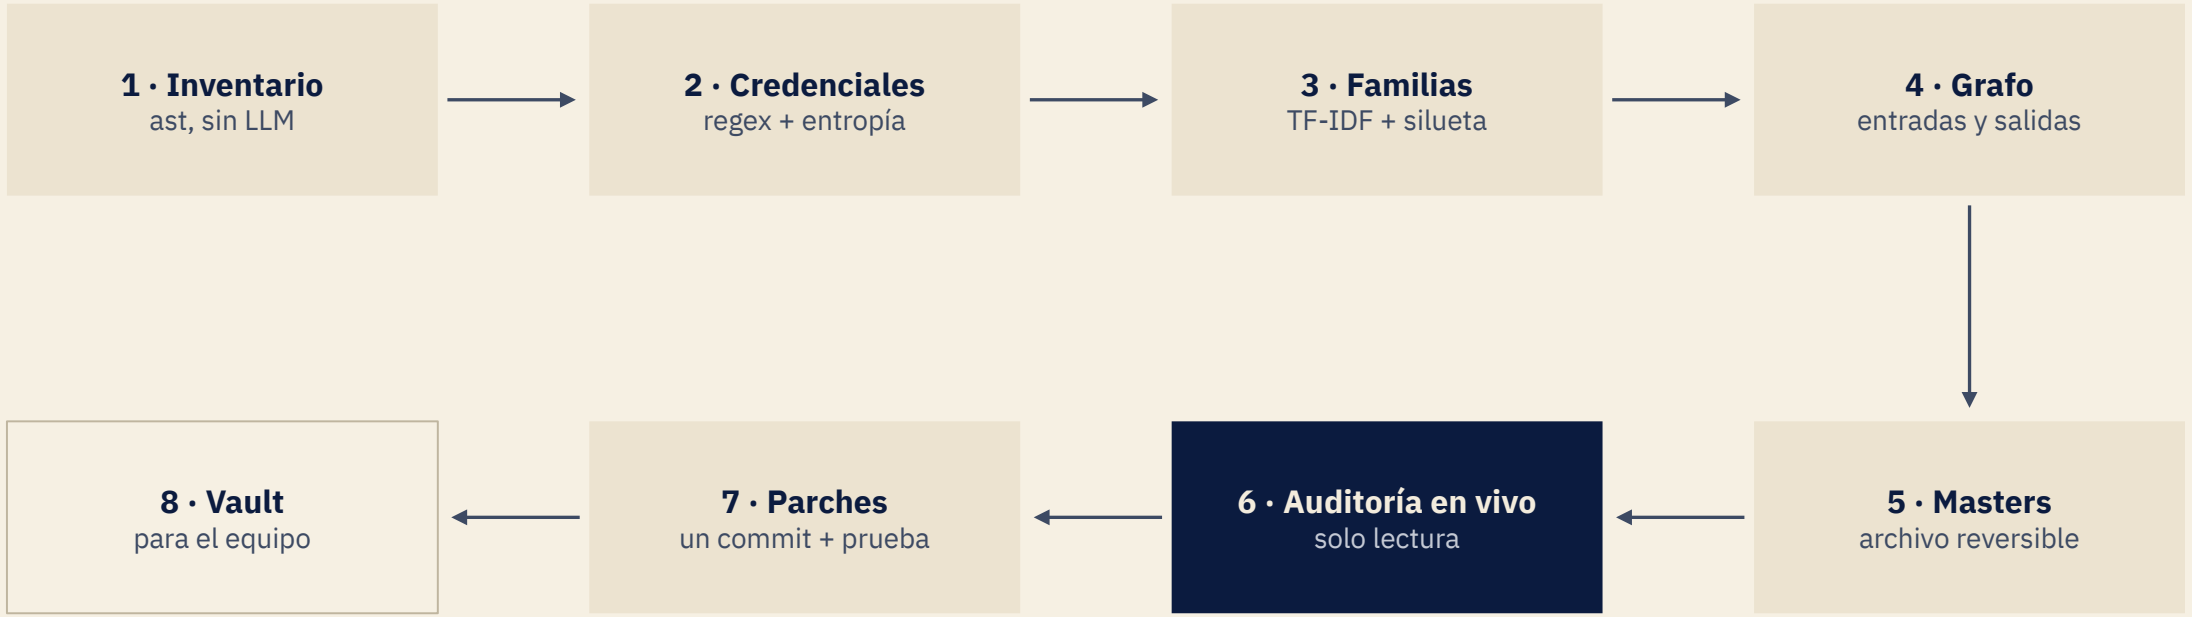
Seguridad y coste

- Una llave en un notebook compartido es una llave publicada
- Un reintento mal escrito multiplica la factura sin avisar

Confianza en las cifras

- Si la misma ventana da dos resultados, ninguno vale
- Un «0» que en realidad es «no medido» engaña a quien decide

Capa mecánica barata primero; criterio humano después



En días: qué hay, cuánto cuesta y qué corregir primero

0.97

acuerdo con las familias reales (ARI)

Agrupar por nombre de archivo da 0.11

100 %

de las credenciales encontradas

0 falsas alarmas en 10 señuelos; solo regex: 8

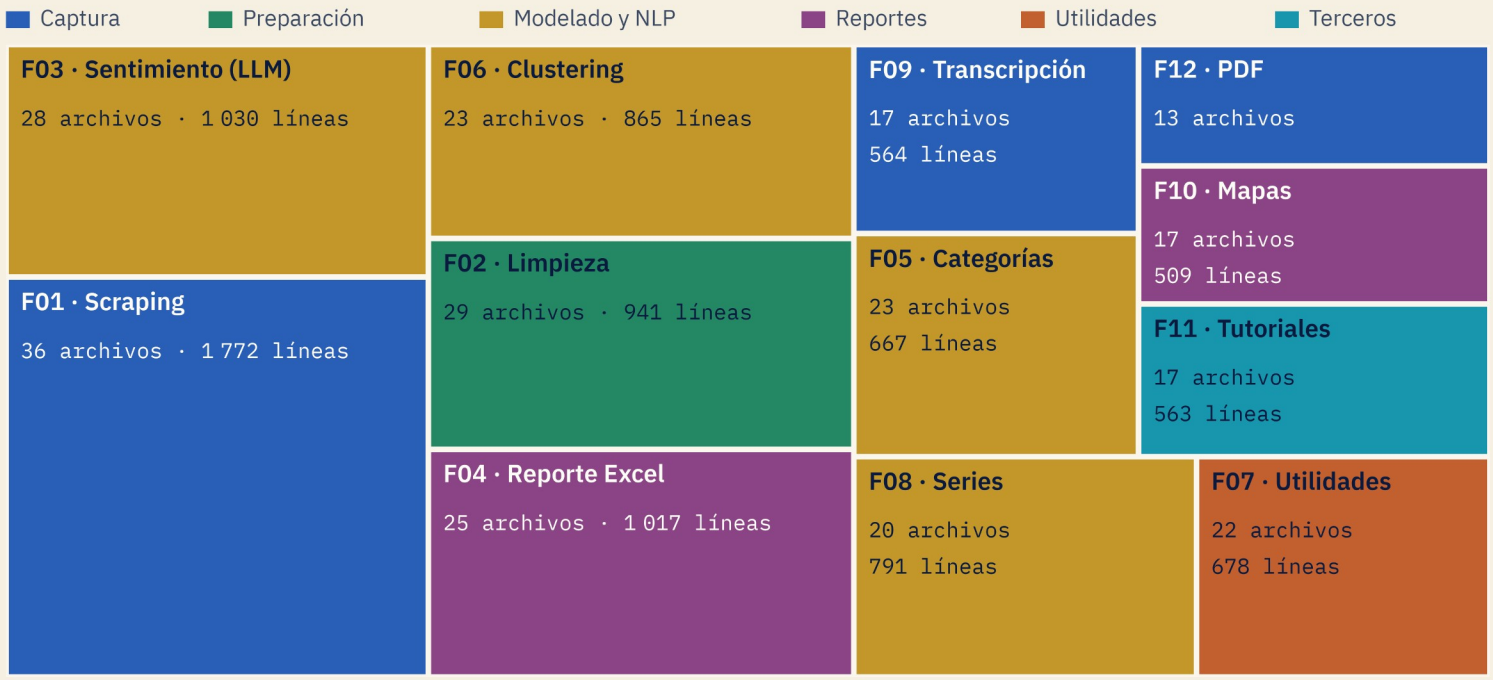
3.0×

coste real frente al presupuesto

Tras el parche: 1.02× (solo reintentos justificados)

Verdad del simulador: repositorio sintético con problemas plantados · Datos ilustrativos (sintéticos) · AI Way

270 archivos resultan ser 12 familias



Fuente: repositorio sintético · verdad del simulador · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) ARI 0.97 contra la verdad del simulador; por nombre de archivo, 0.11

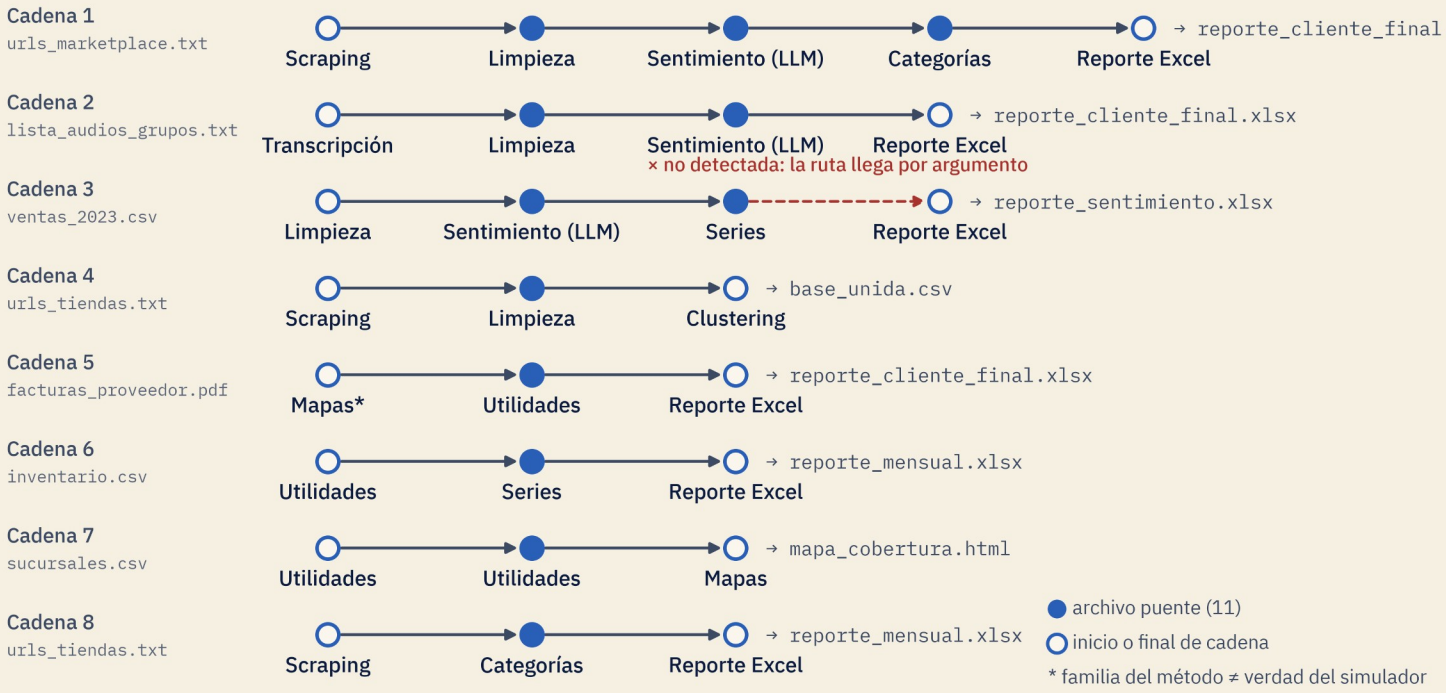
(2) El canónico propuesto acierta en 100 % de las familias

(3) Ponderar imports no superó al TF-IDF plano (0.93 vs 0.96 en réplicas): lo decimos

Límite declarado

Variantes generadas por mutación: es una cota optimista; en un repositorio real habrá más revisión humana.

Ocho cadenas sostienen el trabajo; el resto son variantes



Fuente: repositorio sintético · verdad del simulador · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) 19 de 20 enlaces plantados recuperados, sin enlaces falsos

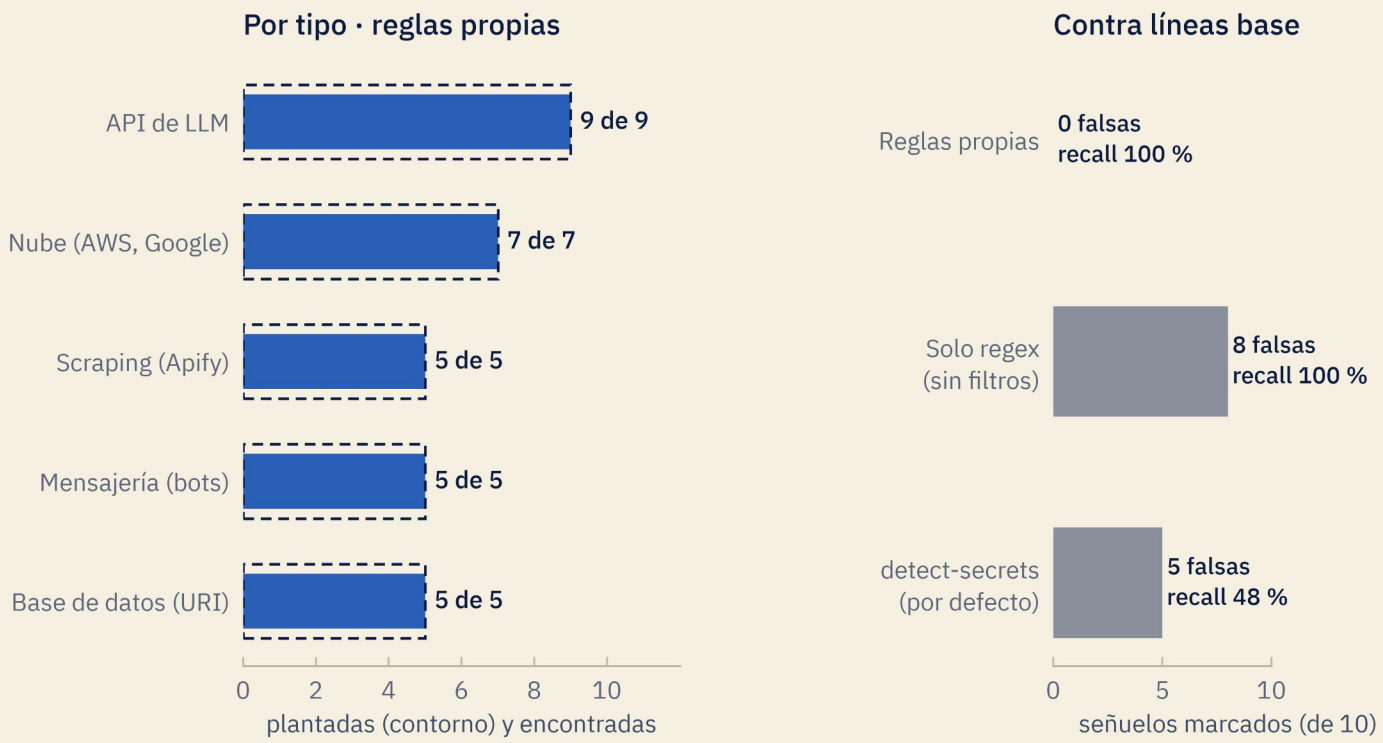
(2) 11 archivos puente: si uno se rompe, se cae su cadena

(3) Un enlace llega por argumento: sin ejecutar no se ve, y se reporta

Límite declarado

El grafo sale de rutas escritas en el código; lo que se decide en tiempo de ejecución requiere revisar corridas reales.

Todas las credenciales encontradas, sin falsas alarmas



Fuente: repositorio sintético · verdad del simulador · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) 31 de 31 credenciales falsas en 25 notebooks

(2) Entropía y contexto descartan hashes, UUID y ejemplos: 0 vs 8 falsas alarmas con solo regex

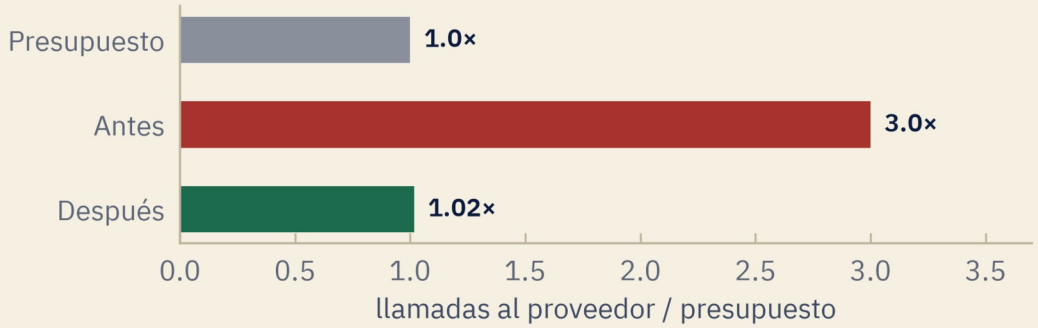
(3) El reporte guarda tipo y ubicación, nunca el valor

Límite declarado

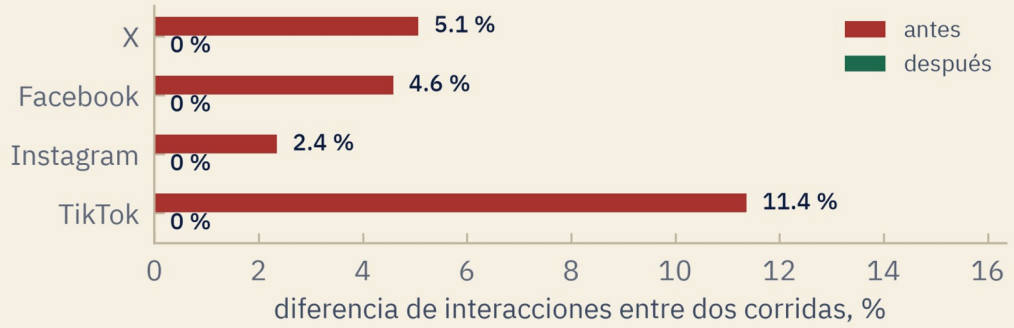
Las reglas conocen estos formatos; un proveedor nuevo exige agregar su patrón.

Costaba 3.0× lo presupuestado y no daba lo mismo dos veces; 4 de 4 parches lo corrigen

1 · Coste por corrida: el reintento repetía cada llamada



2 · Misma ventana, dos corridas: antes ≠, después =



3 · Reanudar tras una interrupción (doble camino)

Antes `publicado 3 702 · recuento 3 723`

× bloqueado: faltan 21 menciones

Después `publicado 3 723 · recuento 3 723`

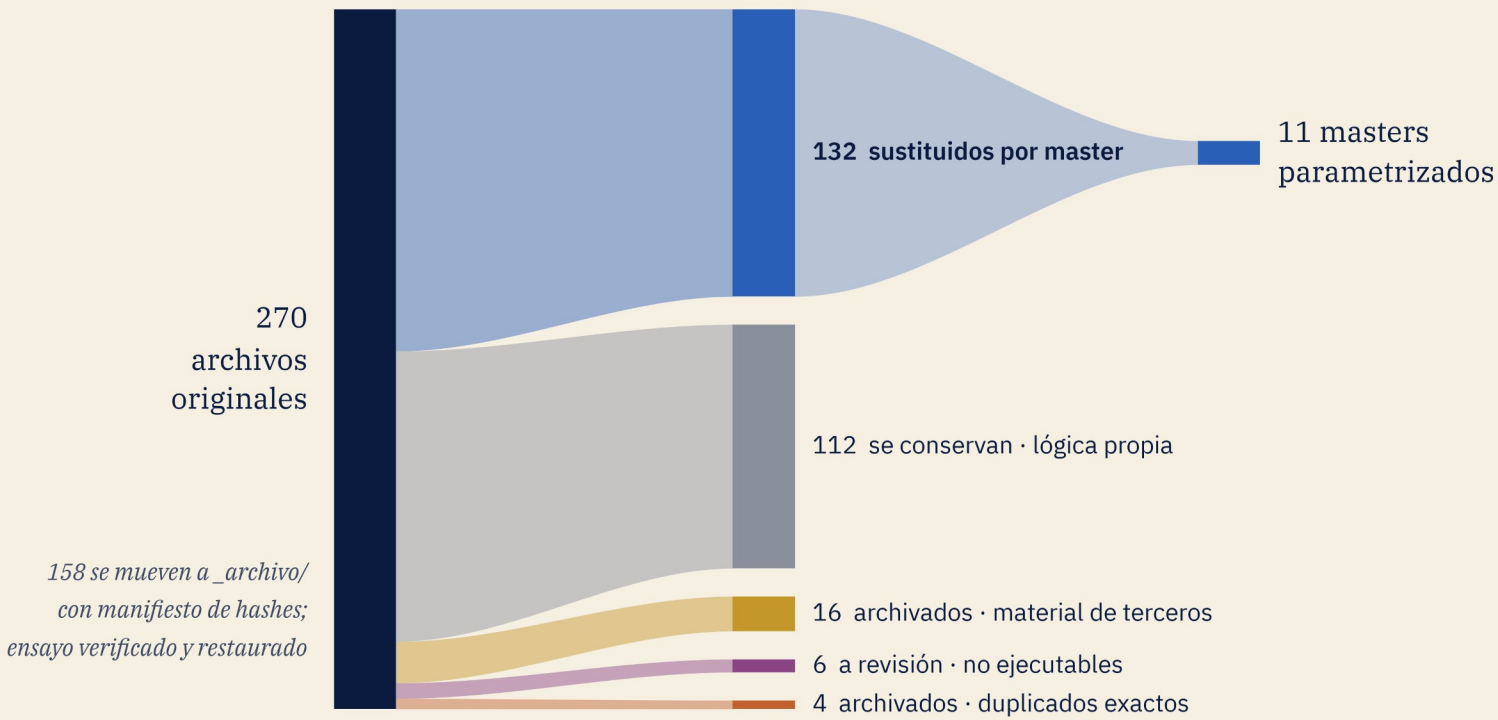
✔ publicable

4 · Un 0 que en realidad era «no medido»



Fuente: repositorio sintético · verdad del simulador · Datos ilustrativos (sintéticos) · AI Way

132 archivos sustituidos por 11 masters, nada borrado



Fuente: repositorio sintético · verdad del simulador · Datos ilustrativos (sintéticos) · AI Way

Lectura

(1) Cada master trae configuración al inicio y credenciales por variables de entorno

(2) Solo se sustituye lo que el master cubre por completo; 112 se conservan

(3) Las fichas son 20 veces menos material que el repositorio

Límite declarado

Que un master cubra las funciones no garantiza resultados idénticos: cada uno se valida contra corridas reales.

Caso de estudio

Tres años de notebooks, consolidados en masters

Entregado

REPOSITORIO PROPIO DE PROYECTOS CON CLIENTES DE VARIAS INDUSTRIAS

Problema

Cientos de notebooks sin nombre informativo, con credenciales en el código y trabajo repetido.

Qué hicimos

- Inventario con 42 campos por notebook
- 88 familias por similitud y grafo de dependencias
- Credenciales marcadas por tipo, nunca por valor
- Archivado reversible con manifiesto

205 → 18

originales sustituidos por masters parametrizados

~183×

menos material en fichas que leer el código completo

Lo que no está medido

El tiempo ahorrado al equipo no se midió con rigor.

Caso real anonimizado · cifras sensibles en relativo

Caso de estudio

Una operación heredada que costaba más de lo presupuestado

Entregado

MONITOREO HEREDADO DE OTRO PROVEEDOR · CLIENTE CORPORATIVO

Problema

El sistema recibido costaba más de lo previsto y la misma ventana daba cifras distintas.

Qué hicimos

- Auditoría en modo solo lectura del sistema recibido
- Coste real medido contra el presupuesto
- Misma ventana de 24 h corrida dos veces
- Parches quirúrgicos: un commit por corrección

~3.2×

coste real frente a lo presupuestado

~7×

diferencia entre dos corridas de la misma ventana

Lo que no está medido

Montos y volúmenes absolutos: no se publican, por acuerdo con el cliente.

Caso real anonimizado · cifras sensibles en relativo

Tres formas de empezar

Nº 01

Básico

Para saber qué tiene su repositorio

- Inventario automático
- Familias y grafo
- Reporte de credenciales
- Recomendaciones priorizadas

1 a 2 semanas

Nº 02

Pro

Para el pipeline que no puede fallar

- Todo el Básico
- Auditoría en vivo de un pipeline
- Parches con prueba
- Masters de 5 familias

4 a 6 semanas

Nº 03

Enterprise

Para dejarlo operable

- Consolidación completa
- Pipeline reanudable con QA
- Vault de conocimiento
- Acompañamiento del equipo

8 a 12 semanas

Stack: Python (ast, nbformat), scikit-learn, NetworkX, git, pytest, Markdown/Obsidian · Datos ilustrativos (sintéticos) · AI Way

Qué decisiones habilita una auditoría de datos

OPERACIÓN Y COSTOS

¿Por qué el pipeline cuesta más de lo presupuestado?

Auditamos en solo lectura el coste real por corrida y lo comparamos con el presupuesto, fuente por fuente.

→ *Corregir el paso que dispara el coste o ajustar el presupuesto.*

RIESGO Y SEGURIDAD

¿Hay claves de API expuestas en nuestro código?

Escaneamos notebooks y scripts con reglas y contexto; reportamos tipo y ubicación, nunca el valor.

→ *Rotar credenciales por orden de riesgo y sacarlas del código.*

VENTAS E INGRESOS

¿Las cifras del tablero comercial son correctas?

Verificamos fórmulas y KPIs contra la definición del negocio y probamos cada corrección.

→ *Volver a confiar en el tablero o corregirlo antes del cierre.*

MARKETING

¿El reporte de campaña da lo mismo si lo corremos dos veces?

Corremos el pipeline dos veces con la misma ventana y medimos la diferencia y la cobertura por fuente.

→ *Publicar resultados reproducibles o frenar el reporte hasta corregir.*

DIRECCIÓN Y ESTRATEGIA

¿Reescribimos el sistema heredado o lo fortalecemos?

Inventario sin LLM, familias por similitud y grafo de dependencias muestran qué funciona y qué no.

→ *Elegir entre fortalecer o reescribir con evidencia.*

TALENTO Y CONTINUIDAD

Se fue quien entendía el código, ¿cómo seguimos?

Generamos fichas, masters parametrizados y una vault de conocimiento con pasos, trampas y deuda.

→ *Incorporar a una persona nueva sin depender de quien se fue.*

Ejemplos de aplicación; el alcance se define en el diagnóstico

AI WAY

Hablemos

Cuéntame qué heredaste. En una llamada de 30 minutos te digo qué mediríamos primero y qué no te puedo prometer.

Agenda un diagnóstico

Nombre	Andrés Vázquez Macías
Correo	avm.48p1@gmail.com
Web	andresvama.github.io
LinkedIn	linkedin.com/in/andrés-vázquez-macías-727278242
GitHub	github.com/AndresVAMA



AI Way: soluciones que te hacen decir «¡ay, wey!»